

Alunos: Luiz Henrique Brito, José Ronaldo Silva e Guilherme Pereira
Definição do problema e coleta de dados

Problema

O grupo coloca como problema a ser resolvido a detecção de prompt injection em mensagens enviadas a modelos de inteligência artificial, o objetivo será de identificar binariamente mensagens classificando-as como benignas ou malignas, com priorização para mitigar os falsos positivos, visto que na indústria reduzir a frustração do usuário na possibilidade de digitar uma mensagem normal e ser erroneamente classificada como maligna.

Para o uso de modelos, ainda será discutido, mas um modelo NLP classificador como um BERT small tende a ser considerado. Caso seja entendido que temos poder computacional suficiente, podemos analisar a possibilidade de uso de um modelo maior.

A ideia será de fazer uma aplicação simples simulando um chat, parecido com a experiência de um chatbot convencional, dessa forma, testamos o uso simulado natural do modelo.

DADOS

Usaremos o dataset [geekyrakshit/prompt-injection-dataset](#), que contém um total de 534,434 exemplos distribuídos entre um conjunto de treinamento com 270,520 amostras e um conjunto de teste com 263,914 amostras, mantendo uma proporção equilibrada de aproximadamente 50,6 por cento para treinamento. Cada exemplo é composto por apenas duas colunas: um campo de prompt textual e um rótulo binário indicando se o prompt contém uma injeção de prompt ou não. O dataset apresenta uma distribuição de classes bastante balanceada, com 138,589 exemplos negativos (rótulo 0, representando prompts normais) e 131,931 exemplos positivos (rótulo 1, representando injeções de prompt), resultando em uma proporção de aproximadamente 51 por cento de prompts legítimos contra 49 por cento de tentativas de injeção. Os prompts variam consideravelmente em comprimento e complexidade, desde questões simples sobre tópicos cotidianos até tentativas sofisticadas de contorno de instruções usando técnicas como inversão de tarefas, codificação de instruções secundárias e uso de linguagem natural disfarçada. Exemplos de prompts normais incluem perguntas sobre crises de refugiados, recomendações de livros e planejamento de viagens, enquanto exemplos de injeção incluem instruções explícitas como "Forget all previous tasks" ou técnicas mais veladas que tentam explorar vulnerabilidades através de narrativas elaboradas e formatação de código disfarçada. O dataset contém 261,621 prompts únicos no conjunto de treinamento, com alguns prompts aparecendo múltiplas vezes, sendo que os mais frequentes repetindo-se até 16 vezes. A presença de duplicatas parciais e variações semânticas sugere que o dataset foi construído com atenção à robustez, incluindo múltiplas formas de expressar o mesmo tipo de ataque ou pergunta legítima.