

Resultados — Detecção de Prompt Injection com XGBoost

Resultados — Detecção de Prompt Injection com XGBoost

Visão Geral

Item	Valor
Problema	Classificação binária: prompt injection vs. benigno
Dataset	399.741 amostras · 35 features · classes balanceadas (50,8% / 49,2%)
Modelo	XGBoost 3.2.0 (GPU — CUDA 13.2)
Otimização	Optuna 4.8.0 · 100 trials · TPE Sampler · 5-fold CV
Métrica primária	AUC-ROC (maximização)

Divisão dos Dados

Conjunto	Amostras	%
Treino	319.792	80%
Teste (holdout)	79.949	20%

Estratificação verificada: distribuição de classes idêntica entre treino e teste.

Melhores Hiperparâmetros (Optuna)

Parâmetro	Valor
<code>n_estimators</code> (máx.)	2.639
<code>n_estimators</code> (utilizadas)	2.397 (early stopping)
<code>max_depth</code>	8
<code>learning_rate</code>	0.01424
<code>subsample</code>	0.8461
<code>colsample_bytree</code>	0.9357
<code>min_child_weight</code>	1
<code>gamma</code>	0.00612
<code>reg_alpha</code>	0.8675
<code>reg_lambda</code>	9.86×10^{-8}

AUC-ROC médio na validação cruzada (5-fold): **0.918307**

Métricas no Conjunto de Teste (Holdout)

Métrica	Valor
AUC-ROC	0.9180
AUC-PR	0.9286
Acurácia	0.8266


Métrica	Valor
Precisão	0.8607
Recall	0.7724
F1 Score	0.8142

Matriz de Confusão

	Previsto: Benigno	Previsto: Injection
Real: Benigno	TN = 35.698	FP = 4.916
Real: Injection	FN = 8.951	TP = 30.384

- Taxa de falsos positivos (benignos classificados como injection): 12,1%
- Taxa de falsos negativos (injections não detectadas): 22,8%

Gráficos de Avaliação




Evaluation Plots

Os seis painéis mostram:

1. **ROC Curve** — AUC-ROC = 0.9180, bem acima da linha de base aleatória.
2. **Precision-Recall Curve** — AUC-PR = 0.9286; alta precisão mantida mesmo com recall elevado.
3. **Confusion Matrix (normalizada)** — 87,9% dos benignos e 77,2% das injections classificadas corretamente.
4. **Score Distribution** — boa separação entre as classes; maioria das predições concentrada nos extremos (0 e 1).
5. **Calibration Curve** — probabilidades bem calibradas, próximas à curva perfeita.
6. **Precision/Recall/F1 vs. Threshold** — F1 máximo (~0.814) alcançado com threshold $\approx$ 0.42, próximo ao padrão de 0.5.

Importância das Features




Feature Importance

As três métricas de importância (Gain, Weight, Cover) convergem nas principais features:

- **Gain (impacto médio nas divisões):** `count_override_keyword`, `has_override_keyword`, `keyword_density`, `char_count_no_space`, `uppercase_ratio`.
- **Weight (frequência de uso):** `word_length_variance`, `uppercase_ratio`, `entropy`, `lowercase_ratio`, `special_char_ratio`.
- **Cover (amostras cobertas):** `count_system_keyword`, `has_system_keyword`, `count_override_keyword`, `has_override_keyword`, `has_ignore_keyword`.

Features relacionadas a **palavras-chave de override/system/ignore** e **características tipográficas** (maiúsculas, entropia, densidade de keywords) são as mais discriminativas.

Análise SHAP



SHAP Beeswarm

O beeswarm SHAP (2.000 amostras) confirma e detalha os padrões de importância:

Feature	Direção do impacto
<code>uppercase_ratio</code> alto	forte indicador de injection (SHAP positivo alto)
<code>keyword_density</code> alta	forte indicador de injection
<code>char_count_no_space</code> alto	tendência para injection
<code>has_override_keyword</code> = 1	impacto positivo forte e consistente
<code>sentence_count</code> baixo	associado a injection (textos curtos/diretos)
<code>entropy</code> intermediária	neutro a levemente positivo
<code>unique_words</code> baixo	leve tendência para injection

Textos benignos tendem a apresentar valores baixos nessas features, gerando SHAP negativos.

Análise de Erros

Tipo	Quantidade	% do teste
Falsos Positivos	4.916	6,15%
Falsos Negativos	8.951	11,20%
Corretos (Benigno)	35.698	44,65%
Corretos (Injection)	30.384	38,00%

Os falsos negativos (injections não detectadas) são mais frequentes que os falsos positivos, o que sugere que subconjuntos de injections com escrita natural (baixo `uppercase_ratio` , baixa `keyword_density`) escapam ao modelo.

Artefatos Gerados

Arquivo	Tamanho
models/xgboost_model.json	~46,8 MB
models/best_params.json	0,3 KB
models/evaluation_metrics.json	0,4 KB
models/optuna_study.pkl	66,9 KB
docs/results/images/evaluation_plots.png	~309 KB
docs/results/images/feature_importance.png	~206 KB
docs/results/images/shap_beeswarm.png	~212 KB